Bloom Filter

Jan Werren, Xeno Suter

Dezember 2024

Inhaltsverzeichnis

1	Was ist ein Bloom Filter und die Idee dahinter	2
2	Vor- und Nachteile von Bloom Filtern 2.1 Vorteile	2 2 2
3	Implementierung Bloom Filters 3.1 Struktur	2 2
4	Fehlerwahrscheinlichkeit 4.1 Ergebnisse der Fehlerwahrscheinlichkeit	3
5	Beispiel aus der Praxis	4
6	Programmausgabe	4

1 Was ist ein Bloom Filter und die Idee dahinter

Ein Bloom-Filter ist eine probabilistische Datenstruktur, die überprüft, ob ein Element in einem Set enthalten ist. Er basiert auf einem BitSet und mehreren Hash-Funktionen (murmur3-128). Neue Elemente werden durch Setzen von Bits im Array hinzugefügt. Um zu testen, ob ein Element enthalten ist, wird überprüft, ob alle relevanten Bits der Hashes auf 1 gesetzt sind.

2 Vor- und Nachteile von Bloom Filtern

2.1 Vorteile

- Sehr speichereffizient im Vergleich zu traditionellen Datenstrukturen wie Sets. Speicherplatzkomplexität: O(m) (wobei m die Anzahl der Bits im Bloom-Filter ist).
- Schnelle Einfüge- und Prüfoperationen (Zeitkomplexität: O(k), wobei k die Anzahl der Hash-Funktionen ist).
- Keine *false negatives* möglich. Ein Element, das nicht im Set ist, wird immer korrekt als nicht enthalten erkannt.

2.2 Nachteile

- False positives möglich. Ein Element, das nicht im Set ist, kann fälschlicherweise als enthalten erkannt werden. Die Wahrscheinlichkeit für ein false positive steigt mit der Anzahl der Elemente im Set und der Anzahl der Hash-Funktionen.
- Keine Möglichkeit, die Anzahl der Elemente im Set zu bestimmen.
- Keine Entfernung von Elementen möglich (außer mit Counting Bloom Filters).

3 Implementierung Bloom Filters

3.1 Struktur

Ein Bloom-Filter besteht aus einem Bit-Array der Grösse m und k Hash-Funktionen. Die Hash-Funktionen werden verwendet, um die Positionen im

Bit-Array zu berechnen, an denen die Bits gesetzt werden. Die Anzahl der Hash-Funktionen beeinflusst die Wahrscheinlichkeit von false positives.

4 Fehlerwahrscheinlichkeit

Die Fehlerwahrscheinlichkeit wurde wie folgt getestet:

- Eine definierte Anzahl von Wörtern aus einer Datei words.txt wurde in den Bloom-Filter eingefügt.
- Anschließend wurden 100'000 zufällige Wörter generiert, die sicher nicht in words.txt enthalten waren.
- Für jedes zufällige Wort wurde überprüft, ob der Bloom-Filter es als enthalten markiert.
- Die experimentelle Fehlerwahrscheinlichkeit wurde als Verhältnis der false positives zur Anzahl der getesteten Wörter berechnet.
- Des Weiteren wurde die theoretische Fehlerwahrscheinlichkeit berechnet. Mit folgender Formel:

$$P_{\text{false}}(m,n) = \left(1 - \left(1 - \frac{1}{m}\right)^{k \cdot n}\right)^k$$

wobei

$$k = \left\lceil \frac{m}{n} \ln(2) \right\rceil$$

4.1 Ergebnisse der Fehlerwahrscheinlichkeit

Die berechnete Fehlerwahrscheinlichkeit stimmt eng mit der theoretischen Wahrscheinlichkeit überein Für n=1000 Elemente und p=0.01 ergab der Test:

- Berechnete Fehlerwahrscheinlichkeit: 0.01
- Experimentelle Fehlerwahrscheinlichkeit: 0.0101

5 Beispiel aus der Praxis

Ein typisches Anwendungsbeispiel für Bloom-Filter ist in verteilten Systemen wie **Apache Cassandra**. Cassandra verwendet Bloom-Filter, um schnell zu überprüfen, ob ein bestimmter Schlüssel in einer Datenbank vorhanden sein könnte, bevor eine ressourcenintensive Abfrage durchgeführt wird. Dadurch wird die Abfragezeit erheblich reduziert.

6 Programmausgabe

```
Bitte geben Sie die Wahrscheinlichkeit ]0..1] an:

0
Die Wahrscheinlichkeit muss grösser als 0 sein! Bitte genau lesen...

Bitte geben Sie die Wahrscheinlichkeit ]0..1] an:

0.04
p: 0.04
n: 58110
m: 389318
k: 5
Experimentelle (generierte Testwörter) Fehlerwahrscheinlichkeit: 0.0392
Berechnete Fehlerwahrscheinlichkeit: 0.04022121808446685
```

Abbildung 1: Screenshot der Programmausgabe